

Series temporales

Bàtxelor en Data Science

Semana 4

Docente Yolanda Colom Torrens


Semana 4

Aplicación II de series temporales

[Documento online](#)



1. Introducció. Contextualizació de los datos




La ciudad de Barcelona, ubicada en la costa noreste de España y conocida por su clima mediterráneo, ha enfrentado en los últimos años desafíos importantes relacionados con las temperaturas extremas. Para abordar este fenómeno, hemos seleccionado un conjunto de datos proporcionado por el **Servicio Meteorológico de Cataluña**. Estos datos incluyen registros de temperaturas diarias de diversas ciudades, pero hemos filtrado el conjunto de datos para centrarnos en la ciudad de Barcelona. El conjunto de datos específico utilizado pertenece a la serie **"Observatorio Fabra" con código de serie "Baic0008d"**, que recoge temperaturas máximas y mínimas diarias desde el año 1950 hasta diciembre de 2023.

El propósito de analizar este conjunto de datos es entender cómo se han comportado las temperaturas en Barcelona con sus datos históricos, con el objetivo de prever la evolución climática futura. La predicción de la temperatura no solo tiene implicaciones directas para la vida diaria de los ciudadanos, sino que también es crucial para sectores estratégicos de la ciudad. El turismo, la salud pública, la eficiencia energética, la planificación urbana, la agricultura y otros sectores clave dependen de contar con datos climáticos precisos para anticipar y mitigar los efectos de variaciones y tendencias climáticas.

Las temperaturas extremas durante los meses de verano podrían afectar negativamente a la industria turística, uno de los pilares de la economía local, al dificultar las actividades al aire libre. Asimismo, la salud pública podría verse comprometida, especialmente en lo que respecta a los colectivos más vulnerables, como los ancianos y niños, debido a olas de calor cada vez más frecuentes. Además, la eficiencia energética se verá afectada por el incremento de la demanda de energía para refrigeración, y las predicciones ayudarán a planificar su uso de manera más eficiente y sostenible. También, la planificación urbana se beneficiará de este tipo de predicciones para adaptar las infraestructuras y aumentar los espacios verdes, mitigando los impactos del calor urbano.

2. Temperaturas medias por meses registradas en Barcelona

[Link a gráfico dinámico](#)



3. Métodos de previsión para la serie

Podemos aplicar diversos métodos de previsión, vamos a analizar los candidatos y como basándonos en la teoría podrían ser candidatos para este conjunto de datos de temperaturas en Barcelona:

- **Medias Móviles** al ser un método de suavizamiento simple podría ayudar a destacar la tendencia, pero es probable que no maneje bien la estacionalidad ni la variabilidad estocástica.
- El método de **descomposición** podría separar la serie en tendencia, estacionalidad y ruido, lo cual podría ser útil para entender la estructura de los datos, aunque no ser tan eficaz para predecir cambios irregulares en el futuro.
- **Holt-Winters** suele recomendarse para series con estacionalidad regular y tendencia, ajustando dinámicamente los datos, en este caso podría aplicar muy bien, pero sabemos que puede suavizar demasiado las fluctuaciones extremas.
- **SARIMA** en teoría debería ser el modelo más robusto para capturar tanto estacionalidad como fluctuaciones no regulares en la serie, haciéndolo más flexible y preciso para series complejas como las de temperatura.

4. Determinación del mejor método de predicción

Los modelos Holt-Winters o SARIMA, deberían de ser los óptimos para el conjunto de datos del que disponemos. Vimos en el anterior ejercicio que estos datos tenían una clara estacionalidad y tendencia observada por el histórico de temperaturas de Barcelona. La elección de componentes o tipos puede llevarnos a mayor dificultad o inviabilidad de ejecutarlo con una hoja de cálculo común. Por ese motivo vamos a ejecutar el siguiente paso con **Holt-Winters**.

5. Predicción de un año (HW con Excel)

Creamos una tabla haciendo el cálculo de Nivel (L), Tendencia (T) y Estacionalidad (S) para hacer el pronóstico de temperatura, aplicando también coeficientes de suavizado para cada uno de ellos.

En la imagen se puede ver también los cálculos de error medio y cuadrático medio para los datos muestrales, contenidos entre el año 2008-2012.


Ajustando coeficientes, encontramos que los errores mínimos a los que llegamos con este modelo son MSE=0.85 y MAE=0.95.

[Link a hoja de cálculo](#)

Modelo Holt-Winters

			Coeficientes de suavizado			
			0.025	0.0000001	0.75	
Año	Mes	Yt	Nivel (L)	Tendencia (T)	Estacionalidad (S)	Pronóstico (Yt+n)
2008	1	10.29	10.2900	0.0000	0.0000	10.2900
2008	2	10.33	10.2910	0.0000	0.0293	10.3203
2008	3	10.85	10.3042	0.0000	0.4166	10.7209
2008	4	13.68	10.3782	0.0000	2.5805	12.9587
2008	5	16.44	10.4653	0.0000	5.1262	15.5914
2008	6	20.41	10.5857	0.0000	8.6498	19.2355
2008	7	23.57	10.6941	0.0000	11.8194	22.5135
2008	8	24.21	10.7365	0.0000	13.0600	23.7965
2008	9	20.67	10.6583	0.0000	10.7737	21.4321
2008	10	16.61	10.5378	0.0000	7.2476	17.7854
2008	11	10.55	10.3569	0.0000	1.9567	12.3136
2008	12	7.85	10.2453	0.0000	-1.3073	8.9380
2009	1	7.43	10.2076	0.0000	-2.4100	7.7976
2009	2	8.99	10.2374	0.0000	-1.5381	8.6993
2009	3	11.36	10.3039	0.0000	0.4075	10.7115

			0.8525687	0.9468697
Err Muestra	MSE	MAE		
	0.0000	0.0000		
	0.0097	0.0001		
	0.1291	0.0167		
	0.7213	0.5203		
	0.8486	0.7201		
	1.1745	1.3795		
	1.0565	1.1163		
	0.4135	0.1710		
	0.7621	0.5808		
	1.1754	1.3815		
	1.7636	3.1104		
	1.0880	1.1838		
	0.3676	0.1351		
	0.2907	0.0845		
	0.6485	0.4206		



5. Predicción de un año (HW con Excel)

Para la predicción del año 2013, extra muestral, los errores mínimos a los que llegamos con este modelo son MSE=1.09 y MAE=1.95.

Como disponíamos de los datos observados reales de 2013 también, hemos incluido estos datos en una comparativa con la predicción usando el modelo HW, y aquí podemos comparar en esta gráfica como ha funcionado siendo la línea naranja los datos reales y la línea azul la predicción con este modelo en concreto.

[Link a hoja de cálculo](#)

2013	1	9.16		10.0124		0.8524	0.7266
2013	2	7.77		7.7170		0.0530	0.0028
2013	3	11.24		11.9983		0.7583	0.5751
2013	4	13.65		12.3984		1.2516	1.5665
2013	5	14.71		16.4154		1.7054	2.9085
2013	6	19.59		20.6852		1.0952	1.1995
2013	7	25.59		22.2744		3.3156	10.9932
2013	8	24.94		24.7751		0.1649	0.0272
2013	9	22.12		22.0209		0.0991	0.0098
2013	10	19.63		18.3807		1.2493	1.5609
2013	11	12.3		14.1003		1.8003	3.2413
2013	12	10.17		10.9876		0.8176	0.6684

Datos Reales

0.025 Alpha


0.0000001 Beta

0.75 Gamma

Err Extra Muestra

1.0969 MSE

1.9566 MAE



5. Predicción de un año (bonus SARIMA)

Añadido a la petición de la actividad y extra a lo que se nos requiere, hemos querido poner en práctica otros conocimientos adquiridos este año en otras asignaturas aplicada a las series temporales y probar un modelo SARIMA mediante programación.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from pmdarima import auto_arima
from statsmodels.tsa.statespace.sarimax import SARIMAX

# Leer el archivo Excel
df = pd.read_excel('/content/drive/MyDrive/Carlemany/BCN_Temp_meses_4anys.xlsx')

# Extraer la columna de observaciones (Temperatura)
temperaturas = df['Temperatura'].values

# Utilizamos auto_arima para encontrar los mejores parámetros (p, d, q) y (P, D, Q, m) estacionales
modelo_auto_sarima = auto_arima(temperaturas, seasonal=True, m=12, trace=True, suppress_warnings=True, stepwise=True)


# Mostramos los mejores parámetros encontrados
print(f"Mejores parámetros SARIMA encontrados: {modelo_auto_sarima.order} y {modelo_auto_sarima.seasonal_order}")

# Ajustar un modelo SARIMA con los mejores parámetros
modelo_sarima = SARIMAX(temperaturas, order=modelo_auto_sarima.order, seasonal_order=modelo_auto_sarima.seasonal_order)
resultado_sarima = modelo_sarima.fit()

# Realizar la previsión para los próximos periodos (por ejemplo, 12 meses)
predicciones_sarima = resultado_sarima.forecast(steps=12)

# Graficar las predicciones
plt.figure(figsize=(10, 6))
plt.plot(np.arange(len(temperaturas)), temperaturas, label="Serie Original")
plt.plot(np.arange(len(temperaturas), len(temperaturas) + 12), predicciones_sarima, label="Predicciones SARIMA", color='purple')
plt.title('Predicciones con el modelo SARIMA')
plt.xlabel('Tiempo')
plt.ylabel('Temperatura')
plt.legend()
plt.grid(True)
plt.show()

# Mostrar las predicciones
print("Predicciones SARIMA para los próximos 12 meses:")
print(predicciones_sarima)
```



Best model: ARIMA(1,0,0) (2,1,0) [12] Total fit time: 53.720 seconds
Mejores parámetros SARIMA encontrados: (1, 0, 0) y (2, 1, 0, 12)

Predicciones SARIMA para los siguientes 12 meses: [7.88597887
8.69242673 10.49122182 14.50556055 16.5905548 20.13550412 23.81974048
24.36454762 21.65547903 17.36443842 12.27402975 9.27949536]

Con este [código en Python](#) hemos calculado los parámetros óptimos, ejecutado una predicción y pintado este gráfico para 2013 que en el siguiente paso compararemos con HW y con datos reales.

6. Conclusiones

Error absoluto medio (MAE)

HW=1.0969 vs **SARIMA=1.0183**


Error cuadrático medio (MSE)

HW=1.9566 vs **SARIMA=1.4340**

Ambos modelos han demostrado ser buenos para la predicción, cerca de la línea roja de los datos reales. SARIMA ha demostrado aplicar la teoría de ser la mejor opción para capturar fluctuaciones extremas con mejor resultado de MSE y ligeramente mejor a HW respecto a MAE.

Ambos modelos han funcionado bien, pero la determinación siempre de un modelo debe basarse en el objetivo del uso. **Este objetivo es un análisis a largo plazo, analizar efectos en el cambio climático y ser precisos en futuras fluctuaciones, por este motivo y las mejores métricas seleccionamos SARIMA como método óptimo de predicción.**

Creemos que en una serie de datos muy larga debemos gestionar fluctuaciones o cambios importantes, el cambio climático podría no seguir un patrón estacional en años futuros debiendo capturar tendencias no lineales ni estacionales además de ser flexibles a alguna irregularidad.



¡Gracias!